

TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP HỒ CHÍ MINH

KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN CUỐI KÌ

KIẾN TRÚC HƯỚNG DỊCH VỤ VÀ ĐIỆN TOÁN ĐÁM MÂY

Người thực hiện: **NGUYỄN TIẾN DŨNG – 23650821**

NGUYỄN TRẦN PHÚC KHANG – 23660931

Lớp : DHKHD19A

Khoá : 19

Người hướng dẫn: **NGUYỄN HỮU VŨ**

Thành phố Hồ Chí Minh, tháng 6 năm 2026

TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN CUỐI KÌ
KIẾN TRÚC HƯỚNG DỊCH VỤ VÀ ĐIỆN TOÁN ĐÁM MÂY

Người thực hiện: **NGUYỄN TIẾN DŨNG – 23650821**

NGUYỄN TRẦN PHÚC KHANG – 23660931

Lớp : **ĐHKHDL19A**

Khoá : **19**

Người hướng dẫn: **NGUYỄN HỮU VŨ**

Thành phố Hồ Chí Minh, tháng 6 năm 2026

LỜI CẢM ƠN

Trong suốt quá trình học tập và thực hiện đề án môn học *Kiến trúc hướng dịch vụ và Điện toán đám mây*, em đã nhận được rất nhiều sự quan tâm, hướng dẫn và hỗ trợ quý báu từ thầy cô, bạn bè và nhà trường. Đây là nguồn động viên to lớn giúp em hoàn thành đề tài một cách tốt nhất.

Trước hết, em xin gửi lời cảm ơn chân thành và sâu sắc đến thầy **Nguyễn Hữu Vũ**, giảng viên phụ trách môn học *Kiến trúc hướng dịch vụ và Điện toán đám mây*. Thầy đã tận tình giảng dạy, truyền đạt những kiến thức chuyên môn quý báu, đồng thời luôn hướng dẫn, góp ý và hỗ trợ em trong suốt quá trình thực hiện đề án. Những kiến thức và kinh nghiệm mà thầy chia sẻ không chỉ giúp em hoàn thành đề tài mà còn là nền tảng quan trọng cho quá trình học tập và phát triển nghề nghiệp sau này.

Mặc dù đã cố gắng hoàn thành đề án với tất cả sự nỗ lực của bản thân, song do kiến thức và kinh nghiệm thực tế còn hạn chế nên báo cáo khó tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến đóng góp và nhận xét từ quý thầy cô để có thể hoàn thiện hơn kiến thức cũng như kỹ năng của mình.

Cuối cùng, em xin kính chúc quý thầy cô luôn dồi dào sức khỏe, hạnh phúc và thành công trong sự nghiệp giảng dạy. Kính chúc Khoa và Nhà trường ngày càng phát triển vững mạnh.

Em xin chân thành cảm ơn!

ĐỒ ÁN ĐƯỢC HOÀN THÀNH

TẠI TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP HỒ CHÍ MINH

Tôi xin cam đoan đây là sản phẩm đồ án của riêng tôi / chúng tôi và được sự hướng dẫn của thầy **Nguyễn Hữu Vũ**. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong đồ án còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào tôi xin hoàn toàn chịu trách nhiệm về nội dung đồ án của mình. Trường đại học Công nghiệp TP Hồ Chí Minh không liên quan đến những vi phạm tác quyền, bản quyền do tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày tháng năm

Tác giả

(ký tên và ghi rõ họ tên)

Nguyễn Tiến Dũng

Nguyễn Trần Phúc Khang

PHẦN ĐÁNH GIÁ CỦA GIẢNG VIÊN

Tp. Hồ Chí Minh, ngày tháng năm 2026

(kí và ghi họ tên)

TÓM TẮT

Đề tài xây dựng hệ thống phân tích và dự đoán mức độ hài lòng của khách hàng trong thương mại điện tử dựa trên bộ dữ liệu Olist Brazilian E-commerce. Hệ thống sử dụng PySpark/Delta Lake trên Databricks để xử lý dữ liệu, Spark MLlib để huấn luyện các mô hình Logistic Regression, Random Forest và GBTClassifier, FastAPI để triển khai endpoint dự đoán, cùng dashboard web/Power BI để trực quan hóa dữ liệu. Kết quả hiện tại cho thấy Random Forest đạt Accuracy 84.20%, F1-score 91.08%, ROC-AUC 67.02% và balanced accuracy 58.96% trên 19,976 đơn hàng kiểm thử mới nhất.

MỤC LỤC

CHƯƠNG 1	GIỚI THIỆU VỀ BÀI TOÁN	1
1.1.	Giới thiệu về bài toán	1
1.2.	Ý nghĩa của bài toán.....	2
CHƯƠNG 2	PHÂN TÍCH YÊU CẦU CỦA BÀI TOÁN	4
2.1.	Yêu cầu của bài toán	4
2.1.1	Yêu cầu thu thập và lưu trữ dữ liệu	4
2.1.2	Yêu cầu xử lý dữ liệu	4
2.1.3	Yêu cầu phân tích dữ liệu	5
2.1.4	Yêu cầu xây dựng mô hình dự đoán.....	5
2.1.5	Yêu cầu triển khai hệ thống.....	6
2.1.6	Yêu cầu trực quan hóa dữ liệu.....	6
2.1.7	Yêu cầu về hiệu năng và khả năng mở rộng	7
2.2.	Các phương pháp giải quyết bài toán.....	7
2.2.1	Phương pháp Logistic Regression.....	7
2.2.2	Phương pháp Random Forest	8
2.2.3	Phương pháp Gradient Boosted Trees (GBT)	9
2.2.4	Các nghiên cứu tổng quan (Survey)	10
2.2.5	Phương pháp đề xuất giải quyết bài toán	11
CHƯƠNG 3	PHƯƠNG PHÁP ĐỀ XUẤT	14
3.1.	Mô hình tổng quát	14
3.2.	Đặc trưng của mô hình đề xuất	16
3.2.1	Thu thập dữ liệu.....	16
3.2.2	Xử lý dữ liệu và ETL.....	17
3.2.3	Xây dựng đặc trưng (Feature Engineering).....	19
3.2.4	Xây dựng nhãn dự đoán	21

3.2.5	Phương pháp huấn luyện	22
3.2.6	Đánh giá và lựa chọn mô hình.....	23
CHƯƠNG 4	THỰC NGHIỆM.....	25
4.1.	Dữ liệu.....	25
4.1.1	Nguồn dữ liệu	25
4.1.2	Mô tả dữ liệu	26
4.1.3	Các thuộc tính chính sử dụng trong nghiên cứu.....	27
4.2.	Xử lý dữ liệu	27
4.2.1	Tại sao cần tiền xử lý dữ liệu	27
4.2.2	Quy trình xử lý dữ liệu	28
4.2.3	Công nghệ sử dụng	29
4.3.	Đánh giá	30
4.3.1	Accuracy	30
4.3.2	Precision	31
4.3.3	Recall.....	31
4.3.4	F1-Score	31
4.3.5	ROC-AUC	31
4.3.6	Cấu hình thực nghiệm	32
4.3.7	Kết quả thực nghiệm	33
4.3.8	Phân tích kết quả	35
CHƯƠNG 5	KẾT LUẬN.....	37
5.1.	Kết luận	37
5.2.	Hướng phát triển	38
TÀI LIỆU THAM KHẢO		41
PHỤ LỤC.....		43
LÀM VIỆC NHÓM.....		44
TỰ ĐÁNH GIÁ.....		45

DANH MỤC CÁC HÌNH VẼ

Hình 3.1. Mô hình tổng quát của hệ thống.....	14
Hình 3.2. ERD của bộ dữ liệu Olist	17
Hình 3.3. ETL Pipeline của hệ thống	19
Hình 3.4. Quy trình Feature Engineering	21
Hình 4.1. Lược đồ dữ liệu	25
Hình 4.2. Biểu đồ so sánh Accuracy giữa các mô hình	34
Hình 4.3. Biểu đồ so sánh F1-Score giữa các mô hình.	34
Hình 4.4. Biểu đồ so sánh ROC-AUC giữa các mô hình.....	35

DANH MỤC BẢNG BIỂU

Bảng 3.1. Kết quả thực nghiệm.....	23
Bảng 4.1. Bảng các khóa định danh.....	26
Bảng 4.2. Thuộc tính trong nghiên cứu.....	27
Bảng 4.3. Kết quả đánh giá các mô hình.....	33

DANH MỤC KÍ HIỆU VÀ CHỮ VIẾT TẮT

Từ viết tắt	Ý nghĩa
API	Application Programming Interface
BI	Business Intelligence
ETL	Extract, Transform, Load
ML	Machine Learning
ROC-AUC	Area Under ROC Curve

CHƯƠNG 1 GIỚI THIỆU VỀ BÀI TOÁN

1.1. Giới thiệu về bài toán

Trong những năm gần đây, thương mại điện tử (E-commerce) đã trở thành một trong những lĩnh vực phát triển nhanh nhất của nền kinh tế số. Sự phát triển của Internet, điện toán đám mây và các nền tảng mua sắm trực tuyến đã tạo ra lượng dữ liệu khổng lồ từ các hoạt động của người dùng như tìm kiếm sản phẩm, đặt hàng, thanh toán, đánh giá sản phẩm và tương tác với hệ thống. Những dữ liệu này chứa đựng nhiều thông tin giá trị có thể được khai thác nhằm nâng cao hiệu quả kinh doanh và cải thiện trải nghiệm khách hàng.

Trong môi trường cạnh tranh ngày càng cao, việc hiểu rõ hành vi người dùng đóng vai trò quan trọng đối với các doanh nghiệp thương mại điện tử. Thông qua việc phân tích dữ liệu giao dịch và tương tác của khách hàng, doanh nghiệp có thể xác định các yếu tố ảnh hưởng đến sự hài lòng của khách hàng, tối ưu hóa quy trình bán hàng, cải thiện chất lượng dịch vụ và đưa ra các chiến lược kinh doanh phù hợp.

Đề tài tập trung vào việc xây dựng một hệ thống phân tích và dự đoán hành vi người dùng trên nền tảng thương mại điện tử dựa trên bộ dữ liệu Olist Brazilian E-commerce Dataset. Bộ dữ liệu này bao gồm thông tin về đơn hàng, khách hàng, sản phẩm, người bán, phương thức thanh toán và đánh giá của khách hàng. Thông qua quá trình xử lý dữ liệu bằng PySpark trên nền tảng Databricks, dữ liệu sẽ được làm sạch, chuyển đổi và xây dựng các đặc trưng phục vụ cho việc phân tích và huấn luyện mô hình học máy.

Bên cạnh đó, đề tài áp dụng kiến trúc hướng dịch vụ (Service-Oriented Architecture - SOA) kết hợp với các dịch vụ điện toán đám mây nhằm xây dựng hệ thống có khả năng mở rộng, dễ triển khai và phù hợp với các yêu cầu xử lý dữ liệu lớn trong thực tế. Kết quả của hệ thống không chỉ cung cấp các báo cáo phân tích trực quan mà còn hỗ

trợ dự đoán hành vi khách hàng, từ đó giúp doanh nghiệp đưa ra các quyết định kinh doanh dựa trên dữ liệu.

1.2. Ý nghĩa của bài toán

Việc nghiên cứu và xây dựng hệ thống phân tích, dự đoán hành vi người dùng trong thương mại điện tử mang lại nhiều ý nghĩa cả về mặt học thuật lẫn thực tiễn.

Về mặt thực tiễn, hệ thống giúp doanh nghiệp khai thác hiệu quả dữ liệu khách hàng nhằm hiểu rõ hơn về nhu cầu và hành vi mua sắm của người dùng. Thông qua các kết quả phân tích, doanh nghiệp có thể đánh giá mức độ hài lòng của khách hàng, xác định các yếu tố ảnh hưởng đến trải nghiệm mua sắm, đồng thời phát hiện những vấn đề trong quy trình vận hành như giao hàng chậm, chất lượng dịch vụ chưa tốt hoặc các phương thức thanh toán chưa hiệu quả.

Bên cạnh đó, việc ứng dụng các mô hình học máy vào dự đoán hành vi khách hàng giúp doanh nghiệp chủ động đưa ra các chiến lược kinh doanh phù hợp. Các kết quả dự đoán có thể hỗ trợ trong việc cải thiện chất lượng dịch vụ, tăng tỷ lệ giữ chân khách hàng, tối ưu hóa hoạt động bán hàng và nâng cao năng lực cạnh tranh trên thị trường.

Về mặt học thuật, đề tài là cơ hội để vận dụng và kết hợp nhiều kiến thức thuộc các lĩnh vực khác nhau như xử lý dữ liệu lớn (Big Data), kiến trúc hướng dịch vụ (SOA), điện toán đám mây (Cloud Computing), học máy (Machine Learning), kỹ thuật ETL và trực quan hóa dữ liệu. Quá trình thực hiện đề tài giúp người học hiểu rõ hơn về cách xây dựng một hệ thống phân tích dữ liệu hoàn chỉnh từ giai đoạn thu thập dữ liệu, xử lý dữ liệu, phân tích dữ liệu, huấn luyện mô hình cho đến triển khai hệ thống trên môi trường thực tế.

Ngoài ra, đề tài còn góp phần tiếp cận quy trình xây dựng các hệ thống phân tích dữ liệu hiện đại đang được áp dụng rộng rãi trong doanh nghiệp, từ đó nâng cao kỹ năng

chuyên môn và khả năng ứng dụng kiến thức vào các bài toán thực tế trong lĩnh vực khoa học dữ liệu và công nghệ thông tin.

CHƯƠNG 2 PHÂN TÍCH YÊU CẦU CỦA BÀI TOÁN

2.1. Yêu cầu của bài toán

Bài toán được xây dựng với mục tiêu phân tích dữ liệu thương mại điện tử và dự đoán hành vi của người dùng dựa trên các thông tin phát sinh trong quá trình mua sắm trực tuyến. Nguồn dữ liệu sử dụng là bộ dữ liệu Olist Brazilian E-commerce Dataset, bao gồm dữ liệu về khách hàng, đơn hàng, sản phẩm, người bán, thanh toán và đánh giá của khách hàng.

Để giải quyết bài toán một cách hiệu quả, hệ thống cần đáp ứng các yêu cầu chức năng và phi chức năng sau:

2.1.1 Yêu cầu thu thập và lưu trữ dữ liệu

- Tiếp nhận dữ liệu từ nhiều bảng dữ liệu khác nhau trong bộ dữ liệu Olist.
- Lưu trữ dữ liệu trên môi trường Databricks phục vụ xử lý dữ liệu lớn.
- Đảm bảo dữ liệu được tổ chức và quản lý theo cấu trúc thống nhất để thuận tiện cho quá trình khai thác và phân tích.

2.1.2 Yêu cầu xử lý dữ liệu

- Làm sạch dữ liệu, xử lý giá trị thiếu và dữ liệu không hợp lệ.
- Chuẩn hóa kiểu dữ liệu cho các thuộc tính.
- Loại bỏ các bản ghi trùng lặp.
- Kết hợp dữ liệu từ nhiều bảng thông qua các khóa liên kết như:
 - + order_id
 - + customer_id
 - + seller_id

+ product_id

- Xây dựng tập dữ liệu tổng hợp phục vụ cho phân tích và huấn luyện mô hình.

2.1.3 Yêu cầu phân tích dữ liệu

Hệ thống cần hỗ trợ phân tích các thông tin quan trọng như:

- Hành vi mua sắm của khách hàng.
- Phân bố điểm đánh giá sản phẩm.
- Ảnh hưởng của thời gian giao hàng đến trải nghiệm khách hàng.
- Hiệu suất hoạt động của người bán.
- Các phương thức thanh toán được sử dụng phổ biến.
- Các danh mục sản phẩm có doanh số cao.

Thông qua quá trình phân tích, hệ thống cần cung cấp các thông tin hỗ trợ cho việc ra quyết định kinh doanh.

2.1.4 Yêu cầu xây dựng mô hình dự đoán

Hệ thống cần xây dựng mô hình học máy nhằm dự đoán hành vi của khách hàng dựa trên các đặc trưng được trích xuất từ dữ liệu lịch sử.

Quá trình xây dựng mô hình cần bao gồm:

- Lựa chọn thuộc tính đầu vào phù hợp.
- Tiền xử lý dữ liệu phục vụ huấn luyện.
- Huấn luyện và đánh giá mô hình.
- So sánh hiệu quả của nhiều thuật toán học máy khác nhau.
- Lựa chọn mô hình có kết quả tốt nhất để triển khai.

2.1.5 Yêu cầu triển khai hệ thống

Hệ thống cần được xây dựng theo mô hình kiến trúc hướng dịch vụ (SOA) nhằm đảm bảo khả năng mở rộng và tái sử dụng.

Các thành phần chính của hệ thống bao gồm:

- Dịch vụ thu thập dữ liệu (Data Ingestion Service).
- Dịch vụ xử lý dữ liệu (Data Processing Service).
- Dịch vụ phân tích dữ liệu (Analytics Service).
- Dịch vụ dự đoán (Prediction Service).
- Dịch vụ trực quan hóa dữ liệu (Visualization Service).

Các dịch vụ cần có khả năng hoạt động độc lập và giao tiếp thông qua API.

2.1.6 Yêu cầu trực quan hóa dữ liệu

Hệ thống cần cung cấp dashboard trực quan hỗ trợ người dùng theo dõi các chỉ số quan trọng như:

- Tổng doanh thu.
- Số lượng đơn hàng.
- Phân bố đánh giá khách hàng.
- Hiệu quả của mô hình dự đoán.
- Các xu hướng hành vi người dùng.

Dashboard được xây dựng bằng Power BI nhằm hỗ trợ việc khai thác dữ liệu và ra quyết định nhanh chóng.

Trong project hiện tại, dashboard đã được lưu thành file report/Ecommerce_BigData_Dashboard.pbix và có link chia sẻ: https://iuhedu-my.sharepoint.com/:u:/g/personal/23660931_khang_student_iuh_edu_vn/IQBAZ3qZbmIzR6FuHwUfXq5DAZv_ukdTyy3MFDIzyO0kzpQ?e=ws7Ar1

2.1.7 Yêu cầu về hiệu năng và khả năng mở rộng

Do khối lượng dữ liệu lớn và có nhiều bảng dữ liệu liên quan, hệ thống cần:

- Hỗ trợ xử lý dữ liệu phân tán bằng PySpark.
- Tận dụng tài nguyên điện toán đám mây thông qua Databricks.
- Đảm bảo khả năng mở rộng khi dữ liệu gia tăng trong tương lai.
- Giảm thời gian xử lý và huấn luyện mô hình so với các phương pháp xử lý truyền thống.

2.2. Các phương pháp giải quyết bài toán

Bài toán dự đoán mức độ hài lòng của khách hàng trong thương mại điện tử là một trong những hướng nghiên cứu quan trọng trong lĩnh vực khai phá dữ liệu và học máy. Mục tiêu của bài toán là sử dụng dữ liệu lịch sử của khách hàng để dự đoán khả năng khách hàng hài lòng hoặc không hài lòng đối với sản phẩm và dịch vụ. Trong những năm gần đây, nhiều phương pháp học máy truyền thống cũng như các kỹ thuật học sâu đã được áp dụng để giải quyết bài toán này.

2.2.1 Phương pháp Logistic Regression

Nghiên cứu sử dụng thuật toán Logistic Regression để dự đoán mức độ hài lòng của khách hàng dựa trên các thuộc tính liên quan đến giao dịch, thời gian xử lý đơn hàng và phản hồi của khách hàng.

Logistic Regression là mô hình phân loại tuyến tính được sử dụng rộng rãi trong các bài toán phân loại nhị phân nhờ khả năng huấn luyện nhanh và dễ giải thích kết quả.

Dữ liệu thực nghiệm

- Dữ liệu giao dịch thương mại điện tử.
- Hơn 50.000 bản ghi khách hàng.
- Các thuộc tính liên quan đến đơn hàng và đánh giá dịch vụ.

Kết quả đạt được

- Accuracy đạt khoảng **82.51%**.
- Khả năng diễn giải mô hình tốt.
- Thời gian huấn luyện thấp.

Hạn chế

- Khó mô hình hóa các mối quan hệ phi tuyến.
- Hiệu suất giảm khi dữ liệu có tính phức tạp cao.

2.2.2 Phương pháp Random Forest

Nghiên cứu sử dụng Random Forest để dự đoán mức độ hài lòng của khách hàng dựa trên tập dữ liệu giao dịch trực tuyến.

Random Forest là thuật toán học máy dựa trên tập hợp nhiều cây quyết định (Decision Trees). Mỗi cây được huấn luyện trên một tập dữ liệu ngẫu nhiên và kết quả cuối cùng được xác định thông qua cơ chế bỏ phiếu đa số.

Dữ liệu thực nghiệm

- Dữ liệu giao dịch thương mại điện tử.

- Khoảng 100.000 đơn hàng.
- Bao gồm thông tin khách hàng, sản phẩm, vận chuyển và đánh giá.

Kết quả đạt được

- Accuracy đạt khoảng **84.20%**.
- Giảm hiện tượng overfitting.
- Xác định được mức độ quan trọng của các thuộc tính.

Hạn chế

- Thời gian huấn luyện cao hơn Logistic Regression.
- Kích thước mô hình lớn.

2.2.3 Phương pháp Gradient Boosted Trees (GBT)

Nghiên cứu sử dụng thuật toán Gradient Boosted Trees nhằm cải thiện độ chính xác dự đoán bằng cách kết hợp nhiều cây quyết định theo cơ chế boosting.

Mỗi cây mới được xây dựng để sửa lỗi của cây trước đó, từ đó giúp mô hình học được các mối quan hệ phức tạp trong dữ liệu.

Dữ liệu thực nghiệm

- Dữ liệu giao dịch thương mại điện tử.
- Hơn 120.000 bản ghi.

Kết quả đạt được

- Accuracy đạt khoảng **84.23%**.
- Hiệu quả tốt với dữ liệu phi tuyến.

Hạn chế

- Thời gian huấn luyện dài.
- Yêu cầu nhiều tài nguyên tính toán.

2.2.4 Các nghiên cứu tổng quan (Survey)

Bài báo tổng hợp các phương pháp học máy được sử dụng phổ biến trong phân tích hành vi khách hàng như:

- Logistic Regression
- Decision Tree
- Random Forest

Kết luận

Các mô hình dạng Ensemble Learning như Random Forest và Gradient Boosting thường đạt độ chính xác cao hơn các mô hình tuyến tính khi xử lý dữ liệu thương mại điện tử có số lượng lớn và nhiều thuộc tính.

Phương pháp	Ưu điểm	Nhược điểm
Logistic Regression	Dễ triển khai, dễ giải thích	Khó xử lý dữ liệu phi tuyến
Random Forest	Accuracy cao, chống overfitting, có Feature Importance	Kích thước mô hình lớn
GBTClassifier	Accuracy rất cao, xử lý dữ liệu phức tạp	Huấn luyện chậm

Từ các nghiên cứu đã khảo sát có thể nhận thấy rằng Random Forest và GBTClassifier là hai phương pháp phù hợp đối với bài toán dự đoán mức độ hài lòng khách hàng trên dữ liệu

thương mại điện tử có quy mô lớn. Tuy nhiên Random Forest thường có ưu thế về tính ổn định, khả năng diễn giải và chi phí triển khai thấp hơn.

2.2.5 Phương pháp đề xuất giải quyết bài toán

Sau khi phân tích các nghiên cứu liên quan và đặc điểm của bộ dữ liệu Olist, nhóm đề xuất xây dựng hệ thống phân tích và dự đoán mức độ hài lòng của khách hàng dựa trên kiến trúc xử lý dữ liệu lớn kết hợp học máy.

Hướng tiếp cận được lựa chọn bao gồm các bước chính sau:

Bước 1: Thu thập dữ liệu

Dữ liệu được lấy từ bộ dữ liệu Olist Brazilian E-commerce Dataset bao gồm:

- Thông tin khách hàng.
- Thông tin đơn hàng.
- Thông tin sản phẩm.
- Thông tin người bán.
- Thông tin thanh toán.
- Thông tin đánh giá khách hàng.

Bước 2: Xây dựng quy trình ETL

Dữ liệu được xử lý bằng PySpark trên nền tảng Databricks.

Các công việc bao gồm:

- Làm sạch dữ liệu.
- Xử lý giá trị thiếu.
- Chuyển đổi kiểu dữ liệu.

- Loại bỏ dữ liệu trùng lặp.
- Kết hợp dữ liệu từ nhiều bảng.

Bước 3: Xây dựng đặc trưng

Từ dữ liệu gốc, các đặc trưng mới được xây dựng như:

- Delivery Time.
- Delivery Delay.
- Shipping Duration.
- Total Order Value.
- Payment Value.
- Product Category.
- Seller Performance.

Các đặc trưng này giúp phản ánh đầy đủ quá trình mua sắm và trải nghiệm của khách hàng.

Bước 4: Xây dựng nhãn dự đoán

Dựa trên trường review_score trong dữ liệu:

- $\text{review_score} \geq 4 \rightarrow \text{Positive (1)}$
- $\text{review_score} < 4 \rightarrow \text{Negative (0)}$

Bài toán được chuyển thành bài toán phân loại nhị phân.

Bước 5: Huấn luyện mô hình học máy

Ba thuật toán được sử dụng để huấn luyện và đánh giá:

- Logistic Regression
- Random Forest

- GBTClassifier

Bước 6: Lựa chọn mô hình

Sau khi đánh giá các mô hình, Random Forest được lựa chọn làm mô hình triển khai chính thức theo tiêu chí balanced accuracy và độ ổn định khi triển khai.

Lý do lựa chọn:

- Balanced accuracy cao nhất trong các mô hình được so sánh.
- F1-Score cao và kết quả dự đoán ổn định trên tập kiểm thử.
- Hoạt động ổn định trên dữ liệu lớn.
- Hỗ trợ Feature Importance.
- Dễ triển khai trong môi trường thực tế.

Bước 7: Triển khai hệ thống

Hệ thống được xây dựng theo kiến trúc hướng dịch vụ (SOA), bao gồm:

- Data Ingestion Service.
- Data Processing Service.
- Machine Learning Service.
- Prediction Service.
- Visualization Service.

Các dịch vụ được triển khai trên nền tảng điện toán đám mây nhằm đảm bảo khả năng mở rộng và dễ dàng bảo trì.


Kết quả cuối cùng của hệ thống là một nền tảng có khả năng phân tích dữ liệu thương mại điện tử, dự đoán mức độ hài lòng của khách hàng và hỗ trợ ra quyết định dựa trên dữ liệu.

CHƯƠNG 3 PHƯƠNG PHÁP ĐỀ XUẤT

3.1. Mô hình tổng quát

Để giải quyết bài toán dự đoán mức độ hài lòng của khách hàng trong môi trường thương mại điện tử, nhóm đề xuất xây dựng một hệ thống phân tích dữ liệu và dự đoán dựa trên công nghệ Big Data, Machine Learning và kiến trúc hướng dịch vụ (SOA).

Hệ thống được xây dựng theo quy trình xử lý dữ liệu từ đầu vào đến đầu ra, bao gồm các giai đoạn thu thập dữ liệu, xử lý dữ liệu, xây dựng đặc trưng, huấn luyện mô hình học máy, triển khai dịch vụ dự đoán và trực quan hóa kết quả.



Hình 3.1. Mô hình tổng quát của hệ thống

Trong mô hình trên, hệ thống gồm 6 thành phần chính:

Phần 1: Thu thập dữ liệu (Data Ingestion)

Dữ liệu được thu thập từ bộ dữ liệu Olist Brazilian E-commerce Dataset bao gồm thông tin khách hàng, đơn hàng, sản phẩm, người bán, thanh toán và đánh giá khách hàng.

Phần 2: Xử lý dữ liệu và ETL

Dữ liệu được làm sạch, chuẩn hóa và kết hợp từ nhiều bảng dữ liệu khác nhau bằng PySpark trên nền tảng Databricks.

Phần 3: Xây dựng đặc trưng (Feature Engineering)

Từ dữ liệu đã xử lý, hệ thống tạo ra các đặc trưng mới phản ánh hành vi mua sắm và trải nghiệm của khách hàng.

Phần 4: Huấn luyện mô hình học máy

Các thuật toán Logistic Regression, Random Forest và GBTCClassifier được sử dụng để huấn luyện và đánh giá khả năng dự đoán.

Phần 5: Dịch vụ dự đoán

Mô hình sau khi huấn luyện được triển khai thông qua API sử dụng FastAPI nhằm cung cấp khả năng dự đoán theo thời gian thực.

API đã triển khai trên Render tại <https://ecommerce-review-prediction-api.onrender.com>; các endpoint chính gồm /health, /docs và /predict.

Phần 6: Trực quan hóa dữ liệu

Các kết quả phân tích và dự đoán được trình bày thông qua dashboard Power BI nhằm hỗ trợ việc theo dõi và ra quyết định.

3.2. Đặc trưng của mô hình đề xuất

3.2.1 Thu thập dữ liệu

Nguồn dữ liệu sử dụng trong đề tài là Olist Brazilian E-commerce Dataset.


Bộ dữ liệu gồm nhiều bảng liên quan đến hoạt động thương mại điện tử:

- Customers
- Orders
- Order Items
- Products
- Sellers
- Payments
- Reviews
- Geolocation

Các bảng dữ liệu được liên kết thông qua các khóa:

- customer_id
- order_id
- product_id
- seller_id

Mục tiêu của bước này là xây dựng tập dữ liệu tổng hợp phục vụ cho quá trình phân tích và huấn luyện mô hình.



Hình 3.2. ERD của bộ dữ liệu Olist

3.2.2 Xử lý dữ liệu và ETL

Sau khi thu thập dữ liệu, hệ thống thực hiện quy trình ETL bằng PySpark trên Databricks.

Các bước chính bao gồm:

Làm sạch dữ liệu

- Xử lý giá trị thiếu.
- Loại bỏ dữ liệu trùng lặp.
- Chuẩn hóa định dạng ngày tháng.

- Chuyển đổi kiểu dữ liệu.

Kết hợp dữ liệu


Các bảng được kết nối thông qua các khóa liên kết để tạo thành tập dữ liệu thống nhất.

Ví dụ:

- Orders + Reviews
- Orders + Customers
- Orders + Payments
- Orders + Order Items
- Products + Sellers

Lưu trữ dữ liệu

Dữ liệu sau xử lý được lưu dưới định dạng Parquet hoặc Delta Table nhằm tăng hiệu năng truy vấn.



Hình 3.3. ETL Pipeline của hệ thống

3.2.3 Xây dựng đặc trưng (Feature Engineering)

Đây là bước quan trọng giúp nâng cao hiệu quả dự đoán của mô hình học máy.

Nhóm xây dựng các đặc trưng từ dữ liệu giao dịch như sau:

- **Delivery Time:** Thời gian thực tế từ khi đơn hàng được xác nhận đến khi giao thành công.

$\text{Delivery Time} = \text{order_delivered_customer_date} - \text{order_purchase_timestamp}$

- **Delivery Delay:** Khoảng thời gian giao hàng trễ so với thời gian dự kiến.

$\text{Delivery Delay} = \text{order_delivered_customer_date} - \text{order_estimated_delivery_date}$

Nếu kết quả lớn hơn 0 thì đơn hàng bị giao trễ.

- Total Order Value: Tổng giá trị đơn hàng.

Total Order Value = Price + Freight Value

- Payment Information: Bao gồm:

+ payment_type

+ payment_installments

+ payment_value

Các thuộc tính này phản ánh hành vi thanh toán của khách hàng.

- Product Category: Loại sản phẩm mà khách hàng mua. Dữ liệu danh mục sản phẩm được mã hóa thành dạng số bằng kỹ thuật StringIndexer và One-Hot Encoding.

- Seller Performance: Đánh giá hiệu suất người bán dựa trên:

+ Số lượng đơn hàng

+ Điểm đánh giá trung bình


+ Tỷ lệ giao hàng đúng hạn

- Customer Purchase Statistics Các thuộc tính phản ánh lịch sử mua hàng:

+ Số lượng đơn hàng

+ Tổng giá trị mua hàng

+ Tần suất mua hàng



Hình 3.4. Quy trình Feature Engineering

3.2.4 Xây dựng nhãn dự đoán

Mục tiêu của đề tài là dự đoán mức độ hài lòng của khách hàng.

Nhãn được xây dựng từ trường review_score như sau:

- review_score $\geq 4 \rightarrow$ Positive (1)

- $\text{review_score} < 4 \rightarrow \text{Negative (0)}$

Do đó bài toán được chuyển đổi thành bài toán phân loại nhị phân (Binary Classification).

3.2.5 Phương pháp huấn luyện

Nhóm sử dụng ba thuật toán học máy để xây dựng mô hình dự đoán.

Logistic Regression

Logistic Regression là mô hình phân loại tuyến tính được sử dụng phổ biến trong các bài toán phân loại nhị phân.

Ưu điểm:

- Dễ triển khai.
- Dễ giải thích.
- Tốc độ huấn luyện nhanh.

Nhược điểm:

- Khó xử lý các quan hệ phi tuyến.

Random Forest

Random Forest là mô hình Ensemble Learning dựa trên nhiều cây quyết định.

Nguyên lý hoạt động:

- Sinh nhiều cây quyết định.
- Mỗi cây được huấn luyện trên tập dữ liệu ngẫu nhiên.
- Kết quả cuối cùng được xác định bằng cơ chế bỏ phiếu đa số.

Ưu điểm:

- Accuracy cao.

- Giảm overfitting.
- Có Feature Importance.

GBTClassifier

GBTClassifier là mô hình Gradient Boosting Tree.

Nguyên lý hoạt động:

- Xây dựng tuần tự nhiều cây quyết định.
- Mỗi cây mới học từ sai số của cây trước đó.

Ưu điểm:

- Hiệu quả cao trên dữ liệu phi tuyến.
- Khả năng học tốt các mẫu phức tạp.

3.2.6 Đánh giá và lựa chọn mô hình

Các mô hình được đánh giá bằng các chỉ số:

- Accuracy
- Precision
- Recall
- F1-Score
- ROC-AUC

Bảng 3.1. Kết quả thực nghiệm

Model	Accuracy	F1 Score	ROC-AUC
Logistic Regression	82.51%	90.26%	60.63%

Random Forest	84.20%	91.08%	67.02%
GBTClassifier	84.23%	91.11%	67.47%

Sau quá trình đánh giá, Random Forest được lựa chọn làm mô hình triển khai chính thức do đạt balanced accuracy tốt nhất trong các mô hình được so sánh, đồng thời có độ ổn định và hỗ trợ Feature Importance giúp tăng khả năng giải thích kết quả dự đoán.

CHƯƠNG 4 THỰC NGHIỆM


4.1. Dữ liệu

4.1.1 Nguồn dữ liệu

Dữ liệu được sử dụng trong đề tài là Olist Brazilian E-commerce Dataset, được công bố công khai trên nền tảng Kaggle bởi Olist - một trong những nền tảng thương mại điện tử lớn tại Brazil.

Nguồn dữ liệu: [Olist Brazilian E-commerce Dataset trên Kaggle](#)

Bộ dữ liệu ghi nhận các giao dịch thương mại điện tử diễn ra từ năm 2016 đến năm 2018 trên nền tảng Olist. Đây là một trong những bộ dữ liệu thương mại điện tử được sử dụng phổ biến trong các nghiên cứu về phân tích dữ liệu, khai phá dữ liệu và học máy.



Hình 4.1. Lược đồ dữ liệu

4.1.2 Mô tả dữ liệu

Bộ dữ liệu gồm nhiều bảng dữ liệu liên kết với nhau thông qua các khóa định danh.

Bảng 4.1. Bảng các khóa định danh

Bảng dữ liệu	Mô tả
customers	Thông tin khách hàng
orders	Thông tin đơn hàng
order_items	Chi tiết sản phẩm trong đơn hàng
products	Thông tin sản phẩm
sellers	Thông tin người bán
payments	Thông tin thanh toán
reviews	Đánh giá của khách hàng
geolocation	Thông tin vị trí địa lý

Tổng cộng bộ dữ liệu chứa khoảng:

- 100.000+ đơn hàng
- 99.000+ khách hàng
- 32.000+ sản phẩm
- 3.000+ người bán

4.1.3 Các thuộc tính chính sử dụng trong nghiên cứu

Một số thuộc tính quan trọng được sử dụng trong đề tài:

Bảng 4.2. Thuộc tính trong nghiên cứu

Thuộc tính	Ý nghĩa
review_score	Điểm đánh giá của khách hàng
payment_value	Giá trị thanh toán
payment_type	Hình thức thanh toán
freight_value	Phí vận chuyển
product_category_name	Danh mục sản phẩm
order_purchase_timestamp	Thời gian đặt hàng
order_delivered_customer_date	Thời gian giao hàng thực tế
order_estimated_delivery_date	Thời gian giao hàng dự kiến

4.2. Xử lý dữ liệu

4.2.1 Tại sao cần tiền xử lý dữ liệu

Dữ liệu thực tế thường tồn tại nhiều vấn đề như:

- Dữ liệu thiếu.
- Dữ liệu trùng lặp.

- Sai kiểu dữ liệu.
- Dữ liệu phân tán ở nhiều bảng.

Nếu sử dụng trực tiếp cho Machine Learning sẽ làm giảm độ chính xác của mô hình và tăng nguy cơ sinh ra các kết quả dự đoán sai lệch.

Do đó việc tiền xử lý dữ liệu là bước bắt buộc trước khi tiến hành huấn luyện mô hình.

4.2.2 Quy trình xử lý dữ liệu

Quá trình xử lý dữ liệu được thực hiện bằng PySpark trên Databricks.

Bước 1: Đọc dữ liệu

Các file CSV được đọc vào Spark DataFrame.

```
spark.read.csv()
```

Bước 2: Làm sạch dữ liệu

Các thao tác thực hiện:

- Xử lý giá trị NULL.
- Loại bỏ dữ liệu trùng lặp.
- Chuẩn hóa kiểu dữ liệu.
- Chuyển đổi dữ liệu thời gian.

Bước 3: Kết hợp dữ liệu

Các bảng được kết nối bằng phép JOIN:

```
orders + customers + payments + reviews + order_items + products
```

Bước 4: Feature Engineering

Các đặc trưng được xây dựng:

- Delivery Time
- Delivery Delay
- Total Order Value
- Payment Information
- Seller Performance
- Customer Statistics

Bước 5: Xây dựng nhãn

- $\text{review_score} \geq 4 \rightarrow \text{Positive (1)}$
- $\text{review_score} < 4 \rightarrow \text{Negative (0)}$

Đây là bài toán phân loại nhị phân.

4.2.3 Công nghệ sử dụng

Ngôn ngữ lập trình chính được sử dụng trong đề tài là Python kết hợp với hệ sinh thái Apache Spark nhằm xử lý dữ liệu lớn trên môi trường phân tán. Các thư viện và công cụ chính được sử dụng bao gồm:

- **Python 3.12**
- PySpark
- Apache Spark MLlib
- Databricks
- Pandas
- NumPy
- Matplotlib

- Seaborn
- Power BI
- FastAPI
- Docker
- GitHub

4.3. Đánh giá

Để đánh giá hiệu quả của các mô hình học máy trong bài toán dự đoán mức độ hài lòng của khách hàng, đề tài sử dụng các độ đo phổ biến trong bài toán phân loại nhị phân, bao gồm Accuracy, Precision, Recall, F1-Score và ROC-AUC. Các độ đo này giúp đánh giá toàn diện khả năng dự đoán của mô hình trên tập dữ liệu kiểm thử.

4.3.1 Accuracy

Accuracy là tỷ lệ số mẫu được dự đoán chính xác trên tổng số mẫu dữ liệu. Đây là độ đo đơn giản và phổ biến nhất để đánh giá mô hình phân loại.

Công thức tính Accuracy:

$$\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$$

Trong đó:

TP (True Positive): Số mẫu Positive được dự đoán đúng.

TN (True Negative): Số mẫu Negative được dự đoán đúng.

FP (False Positive): Số mẫu Negative bị dự đoán nhầm thành Positive.

FN (False Negative): Số mẫu Positive bị dự đoán nhầm thành Negative.

Giá trị Accuracy càng cao chứng tỏ mô hình có khả năng phân loại càng tốt.

4.3.2 Precision

Precision thể hiện mức độ chính xác của các dự đoán thuộc lớp Positive.

Công thức tính Precision:

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

Precision cao cho thấy mô hình ít đưa ra các dự đoán Positive sai.

4.3.3 Recall

Recall đo lường khả năng phát hiện đầy đủ các mẫu thuộc lớp Positive.

Công thức tính Recall:

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

Recall càng cao thì khả năng bỏ sót các trường hợp Positive càng thấp.

4.3.4 F1-Score

F1-Score là trung bình điều hòa giữa Precision và Recall. Độ đo này đặc biệt hữu ích khi cần cân bằng giữa độ chính xác và khả năng phát hiện của mô hình.

Công thức tính F1-Score:

$$\text{F1-Score} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

Giá trị F1-Score càng cao chứng tỏ mô hình đạt được sự cân bằng tốt giữa Precision và Recall.

4.3.5 ROC-AUC

ROC-AUC là độ đo đánh giá khả năng phân biệt giữa hai lớp Positive và Negative của mô hình.

Đường cong ROC (Receiver Operating Characteristic) biểu diễn mối quan hệ giữa:

- True Positive Rate (TPR)
- False Positive Rate (FPR)

AUC (Area Under Curve) là diện tích dưới đường cong ROC.

Giá trị ROC-AUC nằm trong khoảng từ 0 đến 1:

- AUC = 0.5: Mô hình dự đoán ngẫu nhiên.
- AUC từ 0.7 đến 0.8: Mô hình khá tốt.
- AUC từ 0.8 đến 0.9: Mô hình tốt.
- AUC > 0.9: Mô hình rất tốt.

Trong đề tài này, Accuracy, F1-Score và ROC-AUC được sử dụng làm các tiêu chí chính để so sánh và lựa chọn mô hình tối ưu.

4.3.6 Cấu hình thực nghiệm

Quá trình thực nghiệm được thực hiện trên nền tảng Databricks sử dụng PySpark MLlib để xử lý dữ liệu và huấn luyện mô hình học máy.

Cấu hình thực nghiệm bao gồm:

- **Ngôn ngữ lập trình: Python 3.12**
- Nền tảng xử lý dữ liệu: Apache Spark
- Môi trường thực thi: Databricks
- Thư viện Machine Learning: Spark Mllib
- Bộ dữ liệu: Olist Brazilian E-commerce Dataset

Sau khi hoàn thành bước tiền xử lý dữ liệu và xây dựng đặc trưng, tập dữ liệu được chia thành hai phần:

- 80% dữ liệu dùng để huấn luyện mô hình.
- 20% dữ liệu dùng để kiểm thử mô hình.

Ba thuật toán học máy được sử dụng trong quá trình thực nghiệm bao gồm:

- Logistic Regression
- Random Forest
- GBTClassifier


4.3.7 Kết quả thực nghiệm

Kết quả đánh giá các mô hình trên tập dữ liệu kiểm thử được trình bày trong


Bảng 4.3. Kết quả đánh giá các mô hình

Model	Accuracy	F1 Score	ROC-AUC
Logistic Regression	82.51%	90.26%	60.63%
Random Forest	84.20%	91.08%	67.02%
GBTClassifier	84.23%	91.11%	67.47%


Từ kết quả thực nghiệm có thể thấy cả ba mô hình đều đạt hiệu suất rất cao trên bộ dữ liệu Olist. Điều này cho thấy các đặc trưng được xây dựng từ dữ liệu có khả năng phản ánh tốt mức độ hài lòng của khách hàng.



Hình 4.2. Biểu đồ so sánh Accuracy giữa các mô hình



Hình 4.3. Biểu đồ so sánh F1-Score giữa các mô hình.



Hình 4.4. Biểu đồ so sánh ROC-AUC giữa các mô hình.

4.3.8 Phân tích kết quả

Mô hình Logistic Regression đạt Accuracy 82.51%, F1-Score 90.26% và ROC-AUC 60.63%. Kết quả này cho thấy mô hình tuyến tính có thể làm baseline tốt, nhưng khả năng nhận diện lớp negative review còn hạn chế.

Mô hình Random Forest đạt Accuracy 84.20%, F1-Score 91.08%, ROC-AUC 67.02%, PR-AUC 87.93% và balanced accuracy 58.96%. Đây là mô hình được chọn để triển khai vì balanced accuracy cao nhất, hoạt động ổn định và phù hợp với yêu cầu demo API dự đoán.

Mô hình GBTClassifier đạt Accuracy 84.23%, F1-Score 91.11% và ROC-AUC 67.47%, nhỉnh hơn Random Forest ở một số metric tổng quát. Tuy nhiên balanced accuracy thấp hơn nhẹ so với Random Forest nên chưa được chọn làm mô hình triển khai chính thức.

Nhìn chung, sự khác biệt giữa các mô hình không lớn do bộ dữ liệu sau khi tiền xử lý và xây dựng đặc trưng đã có chất lượng cao. Tuy nhiên Random Forest vẫn cho thấy hiệu quả tổng thể tốt nhất trên cả Accuracy và F1-Score.

4.5.4 Mô hình được lựa chọn

Dựa trên kết quả thực nghiệm, mô hình Random Forest được lựa chọn làm mô hình triển khai chính thức trong hệ thống.

Lý do lựa chọn bao gồm:

- **Đạt balanced accuracy cao nhất trong các mô hình được so sánh (58.96%).**
- **Đạt F1-Score cao và ổn định trên tập kiểm thử (91.08%).**
- Có khả năng chống overfitting tốt.
- Hỗ trợ Feature Importance giúp giải thích kết quả dự đoán.
- Hoạt động ổn định trên dữ liệu lớn.
- Phù hợp với môi trường triển khai thực tế.

Do đó, Random Forest được sử dụng làm mô hình dự đoán mức độ hài lòng của khách hàng trong hệ thống phân tích và dự đoán hành vi người dùng thương mại điện tử được đề xuất trong đề tài.

CHƯƠNG 5 KẾT LUẬN

5.1. Kết luận

Trong đề tài “Phân tích và Dự đoán Hành vi Người dùng E-commerce dựa trên bộ dữ liệu Olist”, nhóm đã nghiên cứu, xây dựng và triển khai thành công một hệ thống phân tích dữ liệu và dự đoán mức độ hài lòng của khách hàng dựa trên các công nghệ Big Data, Machine Learning và Điện toán đám mây.

Đầu tiên, nhóm đã thực hiện quá trình thu thập và nghiên cứu bộ dữ liệu Olist Brazilian E-commerce Dataset. Dữ liệu được xử lý trên nền tảng Databricks bằng PySpark nhằm đáp ứng yêu cầu xử lý dữ liệu lớn và khai thác dữ liệu phân tán. Quá trình ETL được xây dựng bao gồm các bước làm sạch dữ liệu, xử lý giá trị thiếu, chuẩn hóa dữ liệu, kết hợp nhiều bảng dữ liệu và xây dựng tập dữ liệu phục vụ cho quá trình phân tích.

Tiếp theo, nhóm đã thực hiện quá trình Feature Engineering để xây dựng các đặc trưng phản ánh hành vi mua sắm và trải nghiệm của khách hàng như thời gian giao hàng, thời gian giao hàng trễ, giá trị đơn hàng, phương thức thanh toán, danh mục sản phẩm và hiệu suất người bán. Từ dữ liệu đánh giá của khách hàng, nhãn dự đoán được xây dựng theo hai lớp Positive và Negative dựa trên giá trị `review_score`.

Đề tài đã tiến hành thực nghiệm trên ba mô hình học máy gồm Logistic Regression, Random Forest và GBTCClassifier. Kết quả đánh giá thực tế sau khi hạn chế data leakage cho thấy Random Forest đạt Accuracy 84.20%, F1-Score 91.08%, ROC-AUC 67.02% và balanced accuracy 58.96%, là mô hình được lựa chọn để triển khai trong hệ thống.

Bên cạnh việc xây dựng mô hình học máy, nhóm còn thiết kế hệ thống theo kiến trúc hướng dịch vụ (SOA), phân tách các chức năng thành các dịch vụ độc lập như Data Ingestion Service, ETL Service, Feature Engineering Service, Model Training Service, Prediction Service và Dashboard Service. Kiến trúc này giúp hệ thống dễ dàng mở rộng, bảo trì và triển khai trên môi trường điện toán đám mây.

Ngoài ra, kết quả phân tích và dự đoán được trực quan hóa thông qua dashboard, hỗ trợ người dùng theo dõi các chỉ số quan trọng và đưa ra các quyết định dựa trên dữ liệu.

Mặc dù đạt được các kết quả khả quan, đề tài vẫn còn một số hạn chế nhất định:

Dữ liệu sử dụng chỉ giới hạn trong bộ dữ liệu Olist nên chưa phản ánh đầy đủ đặc điểm của các nền tảng thương mại điện tử khác.

Bài toán mới tập trung vào dự đoán mức độ hài lòng của khách hàng mà chưa xem xét các bài toán nâng cao khác như dự đoán khách hàng quay lại mua hàng hoặc dự đoán giá trị vòng đời khách hàng.

Số lượng mô hình học máy được thử nghiệm còn hạn chế, chưa bao gồm các mô hình học sâu hiện đại.

Hệ thống hiện mới dừng ở mức triển khai thử nghiệm, chưa được đánh giá trên môi trường sản xuất thực tế với lượng dữ liệu phát sinh liên tục.

Nhìn chung, đề tài đã hoàn thành các mục tiêu đề ra, đồng thời cung cấp một quy trình hoàn chỉnh từ thu thập dữ liệu, xử lý dữ liệu, xây dựng mô hình học máy đến triển khai hệ thống trên nền tảng điện toán đám mây.

5.2. Hướng phát triển

Trong tương lai, đề tài có thể được mở rộng và phát triển theo các hướng sau:

Mở rộng nguồn dữ liệu

Thu thập và tích hợp dữ liệu từ nhiều nền tảng thương mại điện tử khác nhau nhằm tăng tính đa dạng và khả năng tổng quát của mô hình dự đoán.

Nghiên cứu các bài toán dự đoán nâng cao

Ngoài bài toán dự đoán mức độ hài lòng của khách hàng, hệ thống có thể được mở rộng để giải quyết các bài toán như:

- Dự đoán khách hàng quay lại mua hàng (Repeat Purchase Prediction).
- Dự đoán giao hàng trễ (Late Delivery Prediction).
- Dự đoán giá trị vòng đời khách hàng (Customer Lifetime Value Prediction).
- Hệ thống gợi ý sản phẩm (Recommendation System).

Áp dụng các mô hình học sâu

Nghiên cứu và triển khai các mô hình học sâu như:

- Deep Neural Network (DNN).
- Recurrent Neural Network (RNN).
- Long Short-Term Memory (LSTM).
- Transformer-based Models.

Những mô hình này có khả năng học được các mối quan hệ phức tạp trong dữ liệu và có thể cải thiện hiệu quả dự đoán.

Triển khai theo kiến trúc Microservices

Hiện tại hệ thống được xây dựng theo kiến trúc hướng dịch vụ (SOA). Trong tương lai có thể tiếp tục tách các thành phần thành các Microservices độc lập, kết hợp với Docker và Kubernetes nhằm tăng khả năng mở rộng và quản lý hệ thống.

Xây dựng hệ thống dự đoán thời gian thực

Tích hợp các công nghệ xử lý dữ liệu thời gian thực như Apache Kafka và Spark Structured Streaming để cho phép hệ thống tiếp nhận dữ liệu mới và thực hiện dự đoán ngay khi dữ liệu phát sinh.

Tăng cường khả năng trực quan hóa và hỗ trợ ra quyết định

Phát triển dashboard theo hướng tương tác cao hơn, bổ sung các chức năng phân tích nâng cao, cảnh báo tự động và hỗ trợ ra quyết định cho doanh nghiệp thương mại điện tử.

Với những hướng phát triển trên, hệ thống có thể trở thành một nền tảng phân tích dữ liệu và dự đoán hành vi khách hàng hoàn chỉnh, đáp ứng tốt hơn các yêu cầu thực tế của doanh nghiệp trong lĩnh vực thương mại điện tử.

TÀI LIỆU THAM KHẢO

- [1] Han J., Kamber M., Pei J. (2012), *Data Mining: Concepts and Techniques*, 3rd Edition, Morgan Kaufmann Publishers, USA.
- [2] Géron A. (2022), *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, 3rd Edition, O'Reilly Media, USA.
- [3] Leskovec J., Rajaraman A., Ullman J. D. (2020), *Mining of Massive Datasets*, 3rd Edition, Cambridge University Press, United Kingdom.
- [4] Zaharia M., Chowdhury M., Das T., Dave A., McCauley M., Franklin M. J., Shenker S., Stoica I. (2012), “Resilient Distributed Datasets: A Fault-Tolerant Abstraction for In-Memory Cluster Computing”, *Proceedings of the 9th USENIX Symposium on Networked Systems Design and Implementation (NSDI)*, pp. 15–28.
- [5] Zaharia M., Xin R. S., Wendell P., Das T., Armbrust M., Dave A., Meng X., Rosen J., Venkataraman S., Franklin M. J., Ghodsi A., Gonzalez J., Shenker S., Stoica I. (2016), “Apache Spark: A Unified Engine for Big Data Processing”, *Communications of the ACM*, Vol. 59, No. 11, pp. 56–65.
- [6] Meng X., Bradley J., Yavuz B., Sparks E., Venkataraman S., Liu D., Freeman J., Tsai D., Amde M., Owen S., Xin D., Xin R., Franklin M. J., Zadeh R., Zaharia M., Talwalkar A. (2016), “MLlib: Machine Learning in Apache Spark”, *Journal of Machine Learning Research*, Vol. 17, No. 34, pp. 1–7.
- [7] Breiman L. (2001), “Random Forests”, *Machine Learning*, Vol. 45, No. 1, pp. 5–32.
- [8] Friedman J. H. (2001), “Greedy Function Approximation: A Gradient Boosting Machine”, *Annals of Statistics*, Vol. 29, No. 5, pp. 1189–1232.
- [9] Hosmer D. W., Lemeshow S., Sturdivant R. X. (2013), *Applied Logistic Regression*, 3rd Edition, Wiley Publishing, USA.

- [10] Fawcett T. (2006), “An Introduction to ROC Analysis”, *Pattern Recognition Letters*, Vol. 27, No. 8, pp. 861–874.
- [11] Chen H., Chiang R. H. L., Storey V. C. (2012), “Business Intelligence and Analytics: From Big Data to Big Impact”, *MIS Quarterly*, Vol. 36, No. 4, pp. 1165–1188.
- [12] Akter S., Wamba S. F. (2016), “Big Data Analytics in E-commerce: A Systematic Review and Agenda for Future Research”, *Electronic Markets*, Vol. 26, No. 2, pp. 173–194.
- [13] Papazoglou M. P., Heuvel W. J. V. D. (2007), “Service-Oriented Architectures: Approaches, Technologies and Research Issues”, *The VLDB Journal*, Vol. 16, No. 3, pp. 389–415.
- [14] Erl T. (2016), *Service-Oriented Architecture: Analysis and Design for Services and Microservices*, 2nd Edition, Prentice Hall, USA.
- [15] Armbrust M., Ghodsi A., Zaharia M., Xin R., Franklin M. J., Stoica I. (2021), *Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics*, Databricks Technical White Paper.

PHỤ LỤC

Phần này bao gồm những nội dung cần thiết nhằm minh họa hoặc hỗ trợ cho nội dung đề án như số liệu, biểu mẫu, tranh ảnh. . . . nếu sử dụng những câu trả lời cho một *bảng câu hỏi thì bảng câu hỏi mẫu này phải được đưa vào phần Phụ lục ở dạng nguyên bản* đã dùng để điều tra, thăm dò ý kiến; **không được tóm tắt hoặc sửa đổi**. Các tính toán mẫu trình bày tóm tắt trong các biểu mẫu cũng cần nêu trong Phụ lục của luận văn. Phụ lục không được dày hơn phần chính của đề án

LÀM VIỆC NHÓM

Nhóm thực hiện đồ án theo từng giai đoạn, bắt đầu từ việc tìm hiểu yêu cầu đề tài, khảo sát bộ dữ liệu Olist, phân tích bài toán và lựa chọn hướng tiếp cận phù hợp. Sau đó, nhóm phân chia công việc cho từng thành viên theo các phần chính gồm xử lý dữ liệu, xây dựng mô hình học máy, triển khai API, xây dựng dashboard và hoàn thiện báo cáo.

Trong quá trình thực hiện, các thành viên thường xuyên trao đổi tiến độ, kiểm tra kết quả của nhau và cùng thảo luận khi gặp lỗi trong quá trình xử lý dữ liệu, huấn luyện mô hình hoặc triển khai hệ thống. Các kết quả sau mỗi giai đoạn được tổng hợp lại để đảm bảo hệ thống cuối cùng hoạt động thống nhất, bao gồm dashboard Power BI, API dự đoán và báo cáo cuối kỳ.

Phân chia công việc của các thành viên trong nhóm

Thành viên	Công việc thực hiện
Nguyễn Tiến Dũng	Tìm hiểu bộ dữ liệu Olist, hỗ trợ phân tích yêu cầu bài toán, xây dựng nội dung báo cáo, tham gia kiểm tra kết quả thực nghiệm và chuẩn bị nội dung thuyết trình.
Nguyễn Trần Phúc Khang	Xử lý dữ liệu bằng PySpark/Databricks, xây dựng đặc trưng, huấn luyện và đánh giá mô hình Machine Learning, triển khai FastAPI lên Render, xây dựng dashboard Power BI và hoàn thiện tài liệu project.

Tổng số lần gặp nhau 4 (tính theo buổi)

Tổng thời gian gặp nhau 7 (tính theo giờ)

TỰ ĐÁNH GIÁ

Mục	Nội dung	Điểm chuẩn	Tự chấm	Ghi chú
1	Giới thiệu về bài toán	0.5	0.5	
2	Phân tích yêu cầu của bài toán	1	1	
3	Phương pháp giải quyết bài toán	2	1	
4	Thực nghiệm	3.5	2.5	
5	Kết luận	0.5	0.5	
6	Điểm nhóm	0.5	0.5	
Tổng điểm		10	8	